


Exercícios Pandas parte 2-2

Utilize os datasets do arquivo bike.zip e o esquema abaixo para responder às perguntas a seguir:

Sales

Production



Breve descrição

Estes exercícios fazem parte do material teórico da Universidade dos Dados.

Importando bibliotecas e carregando datasets

```
1 import pandas as pd
2 import numpy as np
3
4 brands = pd.read_csv("/content/brands.csv", sep=",")
5 products = pd.read_csv("/content/products.csv", sep=",")
6 order_item = pd.read_csv("/content/order_items.csv", sep=",")
7 order = pd.read_csv("/content/orders.csv", sep=",")
8 store = pd.read_csv("/content/stores.csv", sep=",")
9 customer = pd.read_csv("/content/customers.csv", sep=",")
10 stock = pd.read_csv('/content/stocks.csv', sep=',')
11 staff = pd.read_csv('/content/staffs.csv', sep=',')
```

```
1 # Célula usada para verificar
2 order_item.head(5)
```

	order_id	item_id	product_id	quantity	list_price	discount
0	1	1	20	1	599.99	0.20
1	1	2	8	2	1799.99	0.07
2	1	3	10	2	1549.00	0.05
3	1	4	16	2	599.99	0.05
4	1	5	4	1	2899.99	0.20

Próximas etapas:

[Gerar código com order_item](#)

[Ver gráficos recomendados](#)

[New interactive sheet](#)

✓ Exercício 7

Você trabalha numa empresa de bicicletas e precisa fazer uma clusterização separando marcas caras de baratas. Para isso, você precisará saber a média de preços das bicicletas de cada marca.

Dica: No dataset brands, você encontra as marcas e no products você possui o preço de cada bicicleta. Traga a informação de preço de products para brands usando a coluna brand_id, e, em seguida, faça o agrupamento de preço médio por cada brand.

```
1 # Juntei as duas tabelas que serão usadas na resolução
2 media_preco = brands.merge(products, on="brand_id", how="left")
3
4 # "Filtrei" as duas colunas que interessam: marca e preço!
5 media_preco = media_preco.groupby('brand_name')['list_price'].mean().reset_index()
6
7 # Renomeei as colunas para melhor legibilidade
8 media_preco = media_preco.rename(columns={'brand_name': 'Marca', 'list_price': 'Média_Preço'})
9
10 # Arredondei os números para duas colunas decimais, para melhor leitura
11 round(media_preco, 2)
```



	Marca	Média_Preço	
0	Electra	761.01	
1	Haro	621.99	
2	Heller	2173.00	
3	Pure Cycles	442.33	
4	Ritchey	749.99	
5	Strider	209.99	
6	Sun Bicycles	524.47	
7	Surly	1331.75	
8	Trek	2500.06	

Aprendizados:

- Aprendi a usar merge, além da sua diferença entre join.
- Consolidei o uso do método groupby.
- Aprendi a usar a função rename, usada para renomear linhas, indexes e, no caso do exercício, colunas.

✓ Exercício 8

Agora que você já possui o preço médio de cada marca, você deve separar os valores em 3 grupos, sendo que os nomes de cada agrupamento será a partir dessa lista: ["Barato", "Médio", "Caro"].

Dica: Será que cut ou qcut podem resolver este problema para você?

```
1 # Criei uma nova coluna na tabela do exercício anterior.
2 # Dividi em três quartis e classifiquei entre barato, médio e caro.
3 media_preco['Rótulo'] = pd.qcut(media_preco['Média_Preço'], q=3, labels=['Barato', 'Médio', 'Caro'])
4 media_preco
```

	Marca	Média_Preço	Rótulo	
0	Electra	761.006186	Médio	
1	Haro	621.990000	Médio	
2	Heller	2172.996667	Caro	
3	Pure Cycles	442.333333	Barato	
4	Ritchey	749.990000	Médio	
5	Strider	209.990000	Barato	
6	Sun Bicycles	524.468261	Barato	
7	Surly	1331.753600	Caro	
8	Trek	2500.064074	Caro	

Próximas etapas:

Gerar código com media_preco

☒ Ver gráficos recomendados

New interactive sheet

Aprendizados:

- Usar qcut.
- Conceito de quartis na prática.

Exercício 9

Outra demanda chegou, dessa vez precisamos entender se o preço tem alguma relação com as vendas. Bicicletas mais caras são mais vendidas que as mais baratas? Qual a diferença nas vendas entre cada um dos grupos que levantamos na última pergunta?

Dica: Agora, você precisará partir do DataFrame brands, trazer informações de produtos de cada marca e depois ir na order_items para trazer a quantidade de cada produto vendido. O primeiro join será com a coluna brand_id que é comum ao dataframe brands e ao products. Na sequência, você consegue ver qual coluna existe em products e em order_items para fazermos mais um join? E o último agrupamento, como será feito? A pergunta é quanto cada marca vende, ou seja, o último agrupamento só pode ser com a coluna br...

```

1 preco = brands.merge(products, on="brand_id", how="left")
2 qte_vendida = preco.merge(order_item, on="list_price", how="left")
3
4 qte_vendida = qte_vendida.groupby('brand_name').agg({
5     'list_price': 'mean', # Apliquei média para coluna 'list_price'
6     'quantity': 'sum' # Apliquei soma para a coluna 'quantity'
7 }).reset_index()
8
9 qte_vendida_ordenada = qte_vendida.sort_values(by='quantity', ascending=False)
10 round(qte_vendida_ordenada, 2)

```

	brand_name	list_price	quantity	
0	Electra	658.43	15621.0	
8	Trek	2311.23	10614.0	
7	Surly	1041.87	3500.0	
6	Sun Bicycles	516.41	1697.0	
1	Haro	502.60	834.0	
3	Pure Cycles	444.72	619.0	
4	Ritchey	749.99	222.0	
2	Heller	1469.88	147.0	
5	Strider	230.50	57.0	

Aprendizados:

- Usar o .agg no groupby para aplicar funções em diferentes colunas.
- Usar o método ascending para colocar ascendente ou descendente.

✓ Exercício 10

Uma das coisas mais importantes para sua marca é expandir pelo maior número de estados possíveis. Para isso, precisamos entender quais estados consomem pouco e quais estados consomem muitos produtos. Em outras palavras, precisamos entender de onde vem a receita e onde precisamos gastar mais com marketing, ou entender se seria melhor simplesmente desligar a operação no local. Crie uma tabela resumando os gastos por estado, verifique qual a diferença do estado que mais consome para o estado que menos consome.

Sem dica para a última tarefa!

```
1 df = order.merge(order_item, on='order_id', how='left')
2 df1 = df.merge(customer, on='customer_id', how='left')
3 df1.head(5)
4
5 gasto_estado = df1.groupby('state').agg({
6     'quantity': 'sum',
7     'list_price': 'sum'})
8
9 round(gasto_estado, 2)
```



The image shows a Jupyter Notebook interface. On the left, there is a table with three columns: 'state', 'quantity', and 'list_price'. The table contains three rows of data for states CA, NY, and TX. On the right, there are icons for a table and a bar chart. Below the table, there is a horizontal scrollbar.

state	quantity	list_price
CA	1516	1191373.67
NY	4779	3894954.72
TX	783	640078.18